

Ciência de Dados

conectando conceitos e práticas

Organizadores:

Gilberto Francisco de Oliveira

Daiane Marcela Piccolo

Rosemeiry de Castro Prado

Célio Aparecido Garcia

Ricardo Slavov



ISBN 978-65-5104-006-1
Série Ciência de Dados

Edições Brasil
Jundiaí/SP
www.edicoesbrasil.com.br
sac@edicoesbrasil.com.br

Organizadores:

Gilberto Francisco de Oliveira

Daiane Marcela Piccolo

Rosemeiry de Castro Prado

Célio Aparecido Garcia

Ricardo Slavov

**CIÊNCIA DE DADOS:
conectando conceitos e práticas**

1ª Edição

Edições Brasil

Jundiaí/SP

2022

© Edições Brasil - novembro de 2022

Supervisão: Marlene Rodrigues da Silva Aguiar

Capa e editoração eletrônica: João J. F. Aguiar

Revisão ortográfica: os autores

Conselho Editorial: Prof. Me. João Carlos dos Santos, Prof. Me. Dimas Ozanam Calheiros, Prof. Dr. José Fernando Petrini, Prof.^a Dra. Teresa Helena Buscato Martins.

Colaboradores:

Luciana Passos Marcondes Scarsiotta, Robson P. Bonidia, Daniela Bonifácio Scaleão, Vera Lúcia Silva Camargo, Isaque Katahira, Miguel José das Neves, Denise Bertolucci, Silvio Fernando Barbieri, Eduardo Alves de Freitas, Lia Cupertino Duarte Abino.

Pareceristas:

Marcela Aparecida Penteado Rossini, Evandro Silva, Eliane Oliveira, Rafael Oliva, Miguel José das Neves, Valéria Bacilli, Luciana Passos Marcondes Scarsiotta, Denise Bertolucci, Silvio Fernando Barbieri, Eduardo Alves de Freitas

Todos os direitos reservados e protegidos pela Lei 9610 de 19/02/1998. Todas as informações contidas nesta obra são de exclusiva responsabilidade dos autores. As figuras deste livro são de exclusiva responsabilidade dos autores. Nenhuma parte desta obra pode ser reproduzida ou transmitida por qualquer meio, sem previa autorização por escrito da editora. O mesmo se aplica às características gráficas e à editoração eletrônica desta obra.

Alguns nomes de empresas e respectivos produtos e/ou marcas foram citadas apenas para fins didáticos, não havendo qualquer vínculo das mesmas com a obra.

As editoras, os organizadores e os autores acreditam que todas as informações apresentadas nesta obra estão corretas. Contudo, não há qualquer tipo de garantia de que o uso das mesmas resultará no esperado pelo leitor. Caso seja(m) necessária(s), as editoras disponibilizarão errata(s) em seus sites. Sem prévio aviso, as editoras poderão retirar o livro do site ou promover alterações.

Dados Internacionais de Catalogação na Publicação (CIP)

Ol41c Oliveira, Gilberto Francisco

Ciência de Dados: conectando conceitos e práticas / Gilberto Francisco de Oliveira, Daiane Marcela Piccolo, Rosemeiry de Castro Prado, Célio Aparecido Garcia, Ricardo Slavov (orgs) [et al.] – Jundiaí: Edições Brasil, 2022.

143 p. Série Ciências de Dados - volume 1

Inclui Bibliografia

ISBN: 978-65-5104-006-1

1. Ciência de Dados 2. Informática 3. Tecnologia
I. Título II Série.

CDD: 600

Distribuição GRATUITA mediante cadastro do leitor na editora

Edição Eletrônica / e-book

sac@edicoesbrasil.com.br - www.edicoesbrasil.com.br

Cap. 9 - Recrutamento Preditivo: People Analytics.....	61
Luis Guilherme Da Silva Correa, Natalia Suzan Miranda, Pedro Marçal Ribeiro Junior, Daniela Bonifacio Scaleao	
Cap. 10 - GRACE: Sistema de Recomendação de Currículos com Aprendizado de Máquina.....	65
Ana Clara B. Medeiros, João Fernando V. Francisco, Julia Brugnari P. Longo, Marcos Vinícius R. de Moraes, Mariana de O. Macedo, Robson P. Bonidia	
Cap. 11 - Web Crawler em Repositório Institucional	68
Graciele Fernanda de Souza Pinto, Isaque Katahira	

PARTE 2 - Relatos Técnicos

Cap. 12 - Exposição da Qualidade das Sementes de Ervilhas: germinação e vigor	73
Anna Laura Ferreira dos Santos, Juliana Santos Rocha, Samarone Lins Lessa Filho, Janaína Stella de Sousa	
Cap. 13 - O estudo de Gestão Clínica com ênfase no fluxo de pacientes: um método para aprimorar a qualidade do serviço e agradar seus usuários.....	83
Greicy Boing Maria, Maria Eduarda da Silva Cabral, Vítor Raposo de Medeiros, Érika Fernanda de Caramelo	
Cap. 14 - Desenvolvimento de um dashboard para avaliação da performance de entregas.....	94
David Mariano Gimenez Mota, Guilherme Henrique Guimarães Custódio, Lucas Valente Carnaúba, Lawton Benatti	
Cap. 15 - Contrato de Crédito Imobiliário em Banco	103
Igor Souza Ferreira, Rafaela de Souza Martins Ferreira, Flaviano Agostini de Lima	
Cap. 16 - Desenvolvimento de Visualização de Dados Sobre a Área Comercial de uma Metalúrgica de Pequeno Porte	108
Patrícia Correia de Lima Santos, Hector Kayque Tavares do Nascimento, Luana da Cruz Pessoa	
Cap. 17 - Análise de Potenciais Clientes para Diminuir Riscos e Melhorar Resultados de uma Instituição Financeira.....	120
Matias Ricardo Muent Castro, Natanael Rodrigues de Moraes, Andre Rabeti Alves, Eduardo Aves de Freitas	
Cap. 18 - Solução para acompanhamento de ideias de redução de custo em montadora de veículos	138
Karina Felix de Albuquerque, Karina da Silva Machado	

CAPÍTULO 11

Web Crawler em Repositório Institucional

Graciele Fernanda de Souza Pinto¹
graciele.souza@fatec.sp.gov.br

Isaque Katahira²
isaque.katahira@fatecourinhos.edu.br

^{1,2} Faculdade de Tecnologia de Ourinhos – FATEC-OU

RESUMO

Este estudo apresenta um modelo baseado em ciência de dados aplicada à ciência da informação para auxiliar na recuperação de documentos acadêmicos de repositórios institucionais. Com o objetivo de investigar os procedimentos de extração e tratamento semântico e linguístico de palavras-chave de metadados de documentos indexados em repositórios, foi utilizada a ferramenta *web crawler* para coletar, limpar, organizar e criar uma lista de palavras-chave. Para tanto, foi extraído um corpus de 310.230 mil palavras-chave do Repositório Institucional da Unesp referente ao período de outubro de 2013 a junho de 2021. A limpeza das palavras-chave foi realizada pela exclusão de expressões regulares indicadoras de inconsistências e unificação de palavras-chave com caracteres maiúscula/minúscula. Das 310.230 palavras-chave de autores coletadas, 44.713 foram excluídas, perfazendo um total de 14% das palavras-chave atribuídas no Repositório Institucional da Unesp.

Palavras-chave: Ciência de dados. Ciência da informação. Palavras-chave de autores.

1 INTRODUÇÃO

A Ciência de Dados, como se conhece hoje, foi definida por Cleveland apenas no ano de 1999, durante o encontro bienal do *International Statistical Institute* e publicada em um artigo em 2001, como sendo “[...] um conjunto de técnicas estatísticas para análise de dados[...]” (CLEVELAND, 2001).

O processo de estabelecimento da Ciência de Dados também é observado no campo da Ciência da Informação. Embora, não existam definições fechadas para Ciência da Informação, a contribuição desta Ciência na organização, armazenamento, recuperação, interpretação, transmissão, transformação, e utilização de dados, é relevante (BORKO, 1968).

Um sistema de recuperação de informação é um ambiente mediador entre um conjunto de documentos e seus potenciais requisitantes. Sua eficiência depende da qualidade da representação dos itens de informação (documentos) e das requisições de seus usuários (buscas) (NETO; FERNEDA, 2016).

Diante deste cenário, uma estratégia para recuperação de informação consiste em utilizar programas ou softwares que possam indexar e/ou fazer *downloads* de documentos da *web* de maneira metódica e automatizada, como o *web crawler* (BLÁZQUEZ OCHANDO, 2014).

O objetivo deste estudo é implementar *web crawler* para extrair e realizar tratamento semântico e linguístico de palavras-chave, processamento de linguagem natural, de documentos indexados no Repositório Institucional (RI) da Unesp.

2 MÉTODOS E TÉCNICAS

A coleta de palavras-chave de autores aconteceu no dia 22 de junho de 2021, no Repositório Institucional da Unesp por meio de *web crawler*. Foram coletadas 310.230 palavras-chave de autores, de todas as áreas do conhecimento.

O ambiente de coleta foi preparado utilizando a linguagem de programação *Python* e as bibliotecas *requests*, *BeautifulSoup* e *pandas* foram utilizadas.

Após recuperadas, as palavras-chave de autores foram processadas para termos únicos. As etapas de análise de palavras-chave foram lematização e deduplicação. A lematização foi realizada por meio do processamento de linguagem natural (PNL), com a biblioteca NLTK, enquanto a deduplicação foi executada através de comparação. Com essas ações, foi possível a produção de lista de palavras-chave ranqueadas.

3 RESULTADOS E DISCUSSÕES

Neste estudo, visitamos 32 páginas do RI da Unesp e coletamos 310.230 palavras-chave de autores. Das 310.230 palavras-chave de auto-

res coletadas, 44.713 foram excluídas por representar expressões regulares indicadoras de inconsistências. As palavras-chave excluídas perfazem um total de 14% das palavras-chave de autores atribuídas no RI da Unesp até a data de coleta.

Uma expressão regular pode ser entendida como uma notação algébrica constituída por um conjunto de símbolos que é utilizada para facilitar o processamento de corpus compostos por textos em várias linguagens de programação

(JURAFSKY; MARTIN, 2000). Portanto, o refinamento de palavras-chave de autores em Repositórios Institucionais é necessário, pois no momento da indexação das palavras pode ocorrer a incorporação de um conjunto de símbolos que não representam as palavras-chave dos autores, tornando os documentos indexados não recuperáveis. Neste estudo propomos instrumentos para otimizar o processo de recuperação de informações em Repositórios Institucionais.

Uma nova lista de palavras-chave de autores normalizadas do Repositório Institucional da Unesp foi gerada após o refinamento de palavras-chave. A lista de palavras-chave normalizadas geradas neste estudo, pode ser acessada em [github](#)¹

4 CONCLUSÃO

O tratamento e a geração de uma nova lista de palavras-chave de autores normalizadas do RI da Unesp contribui para que o usuário cumpra com êxito sua pesquisa. A limpeza da base de dados, utilizando *web crawler*, é um procedimento acessível e gerenciador capaz de ser realizado pelo gerenciador do repositório. Com este procedimento o responsável pelo sistema de armazenamento de informação conseguirá eliminar ou minimizar obstáculos entre usuários e as publicações acadêmicas indexadas, além de melhorar a operação e a eficiência dos sistemas de recuperação por meio da geração de uma nova lista de palavras-chave normalizadas.

REFERÊNCIAS

BLÁZQUEZ OCHANDO, Manuel. Nuevos retos de la tecnología web crawler para la recuperación de información. **Métodos de información**, v. 4, n. 7, p. 115-128, 2014. Disponível em: <http://www.metodosdeinformacion.es/mei/index.php/mei/article/viewFile/IIMEI4-N7-115128/832>. Acesso em: 7 jun. 2021.

1 Disponível em: https://github.com/ikatahira/repositorio-unesp-crawler/blob/main/selected_keywords.xlsx. Acesso em: 17 out. 2021.

BORKO, Harold. Information Science: **what is it?** American Documentation, v. 19, n. 1, p. 3- 5, Jan. 1968. Disponível em: <https://www.marilia.unesp.br/Home/Instituicao/Docentes/EdbertoFerneda/k---artigo-01.pdf>. Acesso em: 17 abr. 2021.

CLEVELAND, William Swain. Data science: an action plan for expanding the technical areas of the field of statistics. **International statistical review**, v. 69, n. 1, p. 21-26, 2001. Disponível em: encurtador.com.br/wAOW5. Acesso em: 5 abr. 2021.

JURAFSKY, Dan. **Speech & language processing**. Pearson Education India, 2000. Disponível em: <https://web.stanford.edu/~jurafsky/slp3/ed3book.pdf>. Acesso em 27 de maio de 2021.

NETO, Jorge Janaite; FERNEDA, Edberto. Ontologia como recurso de padronização terminológica no processo de recuperação de informação. **Informação em Pauta**, v. 1, n. 1, p. 30-45, 2016. Disponível em: <https://dialnet.unirioja.es/descarga/articulo/6254130.pdf>. Acesso em: 10 abr. 2021.

“O conteúdo expresso neste capítulo é de inteira responsabilidade dos autores”

Os autores autorizam a publicação e distribuição gratuita deste e-book por meio das editoras ou canais de distribuição indicados pelas referidas entidades.

PARTE 2

Relatos Técnicos