

Ciência de Dados

conectando conceitos e práticas

Organizadores:

Gilberto Francisco de Oliveira

Daiane Marcela Piccolo

Rosemeiry de Castro Prado

Célio Aparecido Garcia

Ricardo Slavov



ISBN 978-65-5104-006-1
Série Ciência de Dados

CAPÍTULO 7

SCRUM Aplicado à Ciência de Dados: uma revisão

Graciele Fernanda de Souza Pinto¹
graciele.souza@fatec.sp.gov.br

Julia Brugnari Pedro Longo²
julia.longo@fatec.sp.gov.br

Lucas Gabriel Sant Ana Alves³
lucas.alves55@fatec.sp.gov.br

Isaque Katahira⁴
isaque.katahira@fatecourinhos.edu.br

Vera Lúcia Silva Camargo⁵
vera.camargo@fatecourinhos.edu.br

^{1,2,3,4,5} Faculdade de Tecnologia de Ourinhos – FATEC-OU

RESUMO

Atualmente têm sido publicados diversos trabalhos de revisão sistemática da literatura. No entanto, são poucos os estudos sobre a aplicação da metodologia ágil *Scrum* em Ciência de dados. Assim, métodos de *machine learning* estão sendo empregados para realizar uma revisão sistemática automatizada a fim de colaborar com uma visão geral do tema. Inicialmente, 25 estudos sobre Scrum e Ciência de dados foram analisados. Dentre estes, 18 satisfaziam aos critérios de inclusão e exclusão de documentos definidos neste estudo. Estes 18 artigos foram selecionados e estão sendo analisados de acordo com sua contribuição. Como resultado, uma análise quali-quantitativa inicial foi desenvolvida e as palavras-chave dos autores mais relevantes foram identificadas apontando que a maioria dos estudos se concentra em investigar como metodologias ágeis podem ser aplicadas em projetos de aprendizado de máquinas.

Palavras-chave: *Machine learning*. Metodologia ágil. Mapeamento sistemático.

1 INTRODUÇÃO

A revisão de literatura é fundamental para a criação de pesquisas fundamentadas e consistentes que buscam avançar na compreensão de uma determinada área (WEBSTER; WATSON, 2002). O processo de revisão pode auxiliar no desenvolvimento de teorias, no reconhecimento de campos em que existe uma infinidade de outras pesquisas e na identificação de áreas pouco exploradas (WEBSTER; WATSON, 2002).

O processo de revisão de literatura pode ser realizado em uma determinada área para identificar, descrever e propor modelos conceituais que sumarizam as informações publicadas, podendo ou não apresentar um recorte temporal (WEBSTER; WATSON, 2002; RAMDHANI; RAMDHANI; AMIN, 2014). A revisão de literatura também pode apresentar tônicas novas ou emergentes que ainda não foram sujeitos de uma revisão de literatura abrangente (RAMDHANI; RAMDHANI; AMIN, 2014). Estes estudos frequentemente resultam de análises iniciais, que descrevem um novo modelo ou definem uma nova área do conhecimento.

As revisões de literatura também podem ser do tipo narrativa, integrativa e sistemática (FERENHOF; FERNANDES, 2016). A revisão narrativa possui caráter tradicional ou exploratório. Neste tipo não são apresentados os critérios utilizados na seleção dos documentos e novos podem ser inclusos pelo autor conforme sua perspectiva, sem a preocupação em esgotar as informações produzidas (FERENHOF; FERNANDES, 2016).

A revisão do tipo integrativa possui como finalidade reunir e sintetizar resultados de pesquisas de uma determinada área do conhecimento, de modo sistemático, ordenado e abrangente, contribuindo assim para o aprofundamento do conhecimento do objeto de estudo investigado (ERCOLE; MELO; ALCOFORADO, 2014).

O método de investigação científica que possui um processo rigoroso e explícito de identificação, seleção, coleta de dados, análise e descrição de contribuições relevantes à pesquisa, é descrito na literatura como revisão sistemática (BORREGO; FOSTER; FROYD, 2014). Este tipo de revisão de literatura, que visa extrair tendências, padrões e relações, é uma síntese rigorosa de todas as pesquisas relacionadas a um determinado tema com procedimentos metódicos explícitos e reproduzíveis (BORREGO; FOSTER; FROYD, 2014).

Neste contexto, o objetivo desta pesquisa é identificar, por meio de revisão sistemática, a aplicação da metodologia Scrum em Ciência de dados. Para tanto, iremos utilizar ferramentas que empreguem métodos de *machine learning* para automatizar o processo de revisão sistemática.

2 METODOLOGIA

Este estudo possui caráter exploratório, e é enquadrado como revisão sistemática da literatura, com abordagem quali-quantitativa. Procedimentos baseados na recomendação PRISMA (*Preferred Reporting Items for Systematic Reviews and Meta-Analyses*) foram utilizados, conforme recomendado por Moher *et al.* (2009). A metodologia adotada possui um fluxograma de quatro etapas (identificação, seleção, elegibilidade e inclusão) que estão sendo adaptadas às necessidades da pesquisa.

Na etapa de identificação, no dia 08 de setembro de 2021, realizamos uma busca nas bases científicas *Web of Science* (WoS) e Scopus, ambas compatíveis com a ferramenta de análise bibliométrica Bibliometrix/Biblioshiny (ARIA; CUCCURULLO, 2017). Com recorte temporal de 01 de janeiro de 2017 a 08 de setembro de 2021 e sem qualquer filtro em relação ao tipo dos documentos. A estratégia de busca realizada foi: (Todos os campos = (“Scrum” AND “Data Science”)) e (Todos os campos = (“Scrum” AND “Ciência de dados”)) para a WoS e (TITLE-ABS-KEY = (“Scrum” AND “Data Science”)) e (TITLE-ABS-KEY = (“Scrum” AND “Ciência de dados”)), para Scopus. Não houve retorno nas duas bases consultadas, nas pesquisas em língua portuguesa.

Nas pesquisas com termos em inglês, nas bases WoS e SCOPUS, foram retornados 10 e 15 documentos respectivamente. Não foram utilizados critérios de exclusão.

Aplicando o critério de unicidade, verificamos que 7 documentos da WoS estavam entre os 15 documentos da SCOPUS. Então, 18 documentos estão sendo lidos na íntegra e nenhum artigo foi eliminado.

Posteriormente, os resultados serão unificados e os 18 documentos, exportados para o formato BibTex e analisados quali-quantitativamente através das ferramentas Bibliometrix/Biblioshiny, (um pacote desenvolvido na linguagem de programação R) e Microsoft Excel®.


3 RESULTADOS E DISCUSSÃO

O número de publicações por ano foi verificado para analisar a tendência na produção do tema pesquisado. Essa análise revelou que 61,11% dos artigos (11/18) foram publicados entre os anos de 2017 e 2019, sendo esse o período com maior número de pesquisas relacionadas aos temas Scrum e Ciência de dados. Essa constatação é representada pela linha de tendência (linha pontilhada) apresentada na Figura 1.

A busca foi realizada em setembro de 2021; portanto, a ocorrência

de um artigo não representa a totalidade de registros do ano de 2021 e, de acordo com a linha de tendência, este número será maior até o fechamento de 2021.

Figura 1 – Número de publicações por ano



Fonte: elaborado pelos autores

Em relação à tipologia dos 18 documentos recuperados, 66,67% dos registros consistem em artigos de conferências (12/18); 16,67% correspondem a artigos de periódicos (3/18); 16,67% representam revisões de conferência (3/18). Todos os registros recuperados foram elaborados em inglês.

Quanto às fontes de publicação e aos termos mais frequentes nas palavras-chave dos autores dos trabalhos analisados, foram identificados que 72,22% dos registros recuperados foram publicados pela editora IEEE em conferências internacionais. Apresentam-se os termos com maior ocorrência nas palavras-chave dos autores, Figura 2.

Em relação às palavras-chave dos autores, os principais termos consistem em “*Agile methodology*” com 7 ocorrências, “*Scrum*” com 5 ocorrências, “*data science*” com 4 ocorrências, “*big data*” com 3 ocorrências, “*machine learning Project*” com 3 ocorrências e “*software engeneering e kanban*” com 2 ocorrências cada.