



SÃO PAULO
GOVERNO DO ESTADO

PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM
DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC
OURINHOS

RELATÓRIO PARCIAL DE ATIVIDADES

Título do Projeto: Aplicação de Redes Complexas e Aprendizado de Máquina para
Classificação de Sequências Biológicas e Similares

Edital: PIBITI CPS-CNPq 2025/2026.

PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC OURINHOS

1. Identificação

Título do Projeto: Aplicação de Redes Complexas e Aprendizado de Máquina para Classificação de Sequências Biológicas e Similares.

Bolsista: Kelven Bertanha do Nascimento

Orientador: Prof. Dr. Isaque Katahira

Co-Orientadora: Prof. Dra. Jéssica Antônio Delgado

Unidade: Centro Paula Souza – Fatec Ourinhos

Período de Vigência: 01/09/2025 a 31/08/2026

Período Abrangido pelo Relatório: 08/09/2025 a 27/02/2026

2. INTRODUÇÃO E OBJETIVOS

Este projeto investiga o uso de Redes Complexas como ferramenta de extração de características (*feature extraction*) para a classificação de sequências biológicas. O objetivo central deste período foi a adaptação do framework BASiNET, migrando da análise de nucleotídeos individuais para a unidade de códons, visando aumentar a sensibilidade biológica do modelo. Como prova de conceito, utilizou-se o genoma do SARS-CoV-2 para validar a construção das redes de transição.

3. ATIVIDADES DESENVOLVIDAS NO PERÍODO

Levantamento e Revisão Bibliográfica: Estudo aprofundado sobre a topologia de redes complexas e análise do estado da arte do framework BASiNET. Foram mapeados 56 artigos que citam a metodologia original, fundamentando a relevância deste estudo.

Desenvolvimento de Software (Python): Implementação de scripts para automação da leitura de arquivos FASTA, segmentação de sequências em tripletos (códon) e construção de grafos direcionados utilizando as bibliotecas *NetworkX* e *Biopython*.

PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC OURINHOS

Inovação Metodológica (Justificativa): > *A principal contribuição tecnológica desenvolvida consistiu na evolução do mapeamento de sequências. Enquanto a abordagem convencional utiliza nucleotídeos (A, C, G, T), esta pesquisa implementou uma lógica baseada em **códons**. Esta adaptação permite capturar a semântica da tradução proteica, elevando o espaço de estados da rede para 64 nós possíveis, o que enriquece o vetor de características para futuros modelos de Machine Learning.*

4. RESULTADOS ALCANÇADOS E PRODUÇÃO CIENTÍFICA

Modelagem de Rede: Geração de redes de transição para o SARS-CoV-2, com identificação de métricas de grau (*In-degree* e *Out-degree*) e tabelas de frequência de códons.

Produção Científica:

1. Apresentação e publicação de resumo expandido no I CISI (Congresso Internacional de Saberes e Inovação).



Certificamos que Kelven Bertanha do nascimento, Isaque Katahira e Jessica Antônio DELGADO, participou(aram) do I CISI - Congresso Internacional de Saberes e Inovação, apresentando o trabalho **BASINET-PY: REVIEW OF METHODOLOGY AND CONCEPTUAL DESIGN FOR PYTHON-BASED BIOLOGICAL SEQUENCE CLASSIFICATION** no Centro Universitário das Faculdades Integradas e Ourinhos - Unifio, evento ocorrido no período de 06/11/2025 a 10/11/2025, contabilizando carga horária total de 25 horas.


Gilson Aparecido Castadelli
Pró-Reitor - Unifio

Ourinhos, 11 de Novembro de 2025 
Odair Francisco
Presidente da Comissão Organizadora - I CISI



PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC OURINHOS

2. Apresentação de resultados no CONAIDUC (Congresso Nacional de Inovação e Educação).



3. Apresentação na I Mostra de Projetos Integradores do AMS - Fatec Ourinhos.



PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC OURINHOS



5. DIFICULDADES ENCONTRADAS E SOLUÇÕES

Identificou-se uma alta carga computacional no processamento de genomas completos. Como solução, foi implementada uma lógica de segmentação em janelas deslizantes (sliding windows) para otimizar a criação das arestas do grafo.

- Processamento: Grande volume de dados em sequências genéticas longas.
- Solução: Implementação de processamento por blocos (segmentação em códons) para otimizar a memória do script Python.

6. CRONOGRAMA PARA O PRÓXIMO PERÍODO

PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC OURINHOS

Fase 1: Engenharia de Atributos e Complexidade (Março - Abril)

- **Cálculo de Métricas Topológicas:** Implementação de métricas além do grau (in/out-degree), como coeficiente de agrupamento, centralidade de proximidade e caminhos mínimos.
- **Extração de Features:** Transformação das métricas da rede de códons em vetores numéricos estruturados (vetorização).
- **Ajuste de Scripts:** Otimização dos scripts Python para processar múltiplos genomas simultaneamente.

Fase 2: Implementação de Aprendizado de Máquina (Maio - Junho)

- **Treinamento de Modelos:** Aplicação dos algoritmos propostos (SVM, Random Forest, XGBoost) para classificar as sequências.
- **Validação e Testes:** Uso de técnicas de validação cruzada (*cross-validation*) e análise de métricas de performance (Acurácia, F1-Score, Curva ROC).
- **Testes de Generalização:** Aplicação do modelo em outros tipos de vírus ou dados similares para testar a versatilidade do método.

Fase 3: Escrita e Divulgação de Resultados (Julho - Agosto)

- **Redação do Relatório Final:** Consolidação de todos os dados, gráficos de desempenho e conclusões obtidas.
- **Artigo Científico Final:** Elaboração de um artigo completo para submissão a uma revista ou congresso de maior impacto, comparando o BASiNET original com a sua adaptação por códons.
- **Simpósio e Avaliação:** Preparação da apresentação final para o Simpósio de Iniciação Científica e Tecnológica do CPS.

Por fim, os resultados parciais indicam que o projeto está em desenvolvimento adequado, com cumprimento das etapas previstas até o momento. A continuidade das atividades permitirá aprofundar a análise e alcançar os objetivos propostos ao final da vigência.

REDAÇÃO DO ARTIGO PRELIMINAR

ADAPTAÇÃO DO *FRAMEWORK* BASINET PARA MAPEAMENTO E ANÁLISE DE FREQUÊNCIA DO GENOMA DO SARS-COV-2 COMO REDE DE CÓDONS

KELVEN BERTANHA DO NASCIMENTO; JÉSSICA ANTONIO DELGADO; MIGUEL JOSÉ DAS NEVES; MARCELA APARECIDA PENTEADO ROSSINI; ROSEMEIRY DE CASTRO PRADO; FABIO NOGUEIRA DE QUEIROZ; ISAU KATAHIRA

PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC OURINHOS

RESUMO

A representação de sequências biológicas por meio de redes complexas tem se consolidado como uma abordagem eficaz para identificação de padrões estruturais e classificação, destacando-se o *framework* BASiNET, que transforma sequências de DNA e RNA em grafos a partir de processos de mapeamento e extração de métricas topológicas. Inspirado neste modelo, o presente trabalho realiza a construção e análise de uma rede de códons do genoma completo do SARS-CoV-2, utilizando *scripts* desenvolvidos em Python. A sequência em formato FASTA foi segmentada em códons, contabilizada e convertida em uma rede de transições dirigidas entre códons consecutivos. Foram geradas tabelas de frequência absoluta, um gráfico de barras dos 20 códons mais frequentes e uma rede direcionada dos 30 mais abundantes. Os resultados revelaram predominância de códons ricos em timidina (T), com TTT sendo o mais frequente. A análise topológica da rede de transições de códons confirmou a existência de hubs de conectividade. Especificamente, o códon ATT foi identificado como o principal hub de convergência, apresentando o maior Grau de Entrada (*In-degree* = 31). Em contraste, os códons TCT e CTT exibiram a maior diversidade de transições subsequentes, com o maior Grau de Saída (*Out-degree* = 31). A modelagem obtida apresenta coerência metodológica com o BASiNET, visto que preserva a ordem sequencial da cadeia e emprega vértices e arestas baseados em símbolos biológicos, ainda que adaptados ao nível de três nucleotídeos. A análise sugere que a rede de códons é uma representação válida para capturar características estruturais significativas do genoma viral e constitui uma etapa preliminar adequada para pipelines de classificação e aprendizado de máquina que utilizam métricas de redes complexas. Futuras investigações podem incluir comparação entre variantes do SARS-CoV-2, cálculo de métricas topológicas avançadas e aplicação de classificadores supervisionados.

Palavras-chave: aprendizado de máquina; grafo direcionado; redes complexas.

1 INTRODUÇÃO

Métodos tradicionais de análise de sequências biológicas frequentemente se baseiam em alinhamentos, modelos probabilísticos e estatísticas sobre frequência de nucleotídeos. Entretanto, abordagens fundamentadas em redes complexas têm expandido significativamente as possibilidades de caracterização estrutural de sequências, ao permitir capturar dependências sequenciais profundas e padrões emergentes não triviais. O *framework* BASiNET — *BiologicAl Sequences NETwork*, proposto por Ito *et al.* (2018), representa um marco nessa área ao transformar sequências de DNA e RNA em grafos por meio de algoritmos de mapeamento e extração de métricas topológicas empregadas em classificadores. Essa abordagem evidencia que grafos são uma forma eficaz de capturar relações entre unidades biológicas e revelar padrões que não são facilmente perceptíveis por métodos lineares.

Nesse contexto, é importante destacar que as sequências biológicas são constituídas por nucleotídeos, unidades químicas fundamentais compostas por uma base nitrogenada, um

PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC OURINHOS

açúcar (ribose ou desoxirribose) e um grupo fosfato. Nos ácidos nucleicos, os nucleotídeos são organizados linearmente formando cadeias que armazenam e transmitem informação genética. No RNA viral, esses nucleotídeos incluem adenina (A), citosina (C), guanina (G) e uracila (U), cuja disposição define a estrutura e a função do material genético.

Com base nesse princípio, o presente trabalho aplica a ideia central do BASiNET — a conversão da cadeia biológica em uma rede — em um nível alternativo de representação: os códons. Códon são unidades formadas por trincas de nucleotídeos que constituem a base da tradução proteica e carregam informações funcionais essenciais. Assim, analisá-los sob a ótica de redes complexas permite explorar relações estruturais internas do genoma viral e pode contribuir para uma compreensão mais refinada dos padrões organizacionais do SARS-CoV-2.

Este estudo tem como objetivo geral modelar a sequência completa do SARS-CoV-2 como uma rede de transições de códons, analisando sua estrutura e discutindo sua relação com o BASiNET, além de avaliar o potencial dessa representação como etapa preliminar para tarefas de classificação e aprendizado de máquina.

2 MATERIAL E MÉTODOS

Este estudo é de natureza computacional, baseado exclusivamente em análise *in silico*. A sequência genômica completa do SARS-CoV-2 foi obtida por meio do *National Center for Biotechnology Information* (NCBI), utilizando o registro de referência NC_045512.2 – isolate Wuhan-Hu-1, disponibilizado em formato FASTA (NCBI, 2020).

A análise foi conduzida no ambiente de programação Python 3.12, utilizando bibliotecas voltadas ao processamento de sequências e modelagem de grafos, incluindo *NetworkX* para estruturação da rede e *Matplotlib* para eventual visualização de dados (PYTHON SOFTWARE FOUNDATION, 2024; HAGBERG; SCHULT; SWART, 2008).

O arquivo FASTA foi importado e convertido em uma sequência linear de nucleotídeos. Em seguida, procedeu-se à segmentação em códons, definindo grupos de três nucleotídeos consecutivos ao longo de toda a cadeia. Para cada par de códons adjacentes, foi construída uma aresta dirigida representando a transição entre eles, formando assim um grafo direcionado de códons. Foram calculadas métricas de conectividade, frequência relativa e padrões de repetição.

2.1 Aquisição da sequência biológica

Foi utilizada a sequência completa do genoma do SARS-CoV-2 (Wuhan-Hu-1), disponibilizada pelo NCBI no formato FASTA. O arquivo foi importado para o ambiente Python, onde foi realizada a leitura e a concatenação dos trechos, resultando em uma sequência única utilizada nas análises subsequentes.

O formato FASTA é um padrão amplamente utilizado na bioinformática para armazenar sequências biológicas, como DNA, RNA ou proteínas, de maneira simples e legível. Cada arquivo FASTA é composto por duas partes essenciais: (i) uma linha inicial de cabeçalho, iniciada obrigatoriamente pelo caractere “>”, que contém um identificador da sequência e, opcionalmente, uma descrição adicional; e (ii) uma ou mais linhas subsequentes

PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC OURINHOS

que apresentam a sequência propriamente dita, representada por caracteres correspondentes aos nucleotídeos ou aminoácidos.

No presente estudo, utilizou-se a sequência completa do SARS-CoV-2 disponibilizada oficialmente pelo NCBI (National Center for Biotechnology Information). No repositório do NCBI, essa sequência é apresentada no formato FASTA sob a seguinte identificação, conforme Figura 1:




Figura 1 – Sequência FASTA do SARS-CoV-2 (NC_045512.2). Fonte: Adaptado de NCBI (2025)

Essa entrada corresponde ao NCBI *Reference Sequence* NC_045512.2, amplamente reconhecida como a sequência genômica de referência do SARS-CoV-2 (Wuhan-Hu-1). O formato FASTA, por sua estrutura simples e compatível com diversas ferramentas computacionais, facilita a leitura automatizada da sequência pelo script desenvolvido neste trabalho e garante a reprodutibilidade das análises realizadas.

2.2 Segmentação da sequência


Inspirado no método BASiNET (ITO *et al.*, 2018), adotou-se uma segmentação da cadeia nucleotídica com *window size* (WS) = 3. Entretanto, enquanto o BASiNET utiliza janelas sobrepostas com *step size* (ST) = 1, neste trabalho optou-se por um *step size* igual ao tamanho da janela (ST = 3), evitando sobreposição e garantindo que cada unidade corresponda exatamente a um códon funcional.

Essa adaptação é metodologicamente coerente, pois códons representam a menor unidade significativa do processo de tradução, permitindo analisar a estrutura e as transições do genoma a partir de seus elementos codificadores naturais.

2.3 Construção da rede de códons

Para cada par consecutivo de códons identificados na sequência, estabeleceu-se uma aresta direcionada no grafo, conectando o códon atual ao subsequente. Cada aresta recebeu um peso correspondente ao número de ocorrências observadas ao longo da sequência completa.

PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC OURINHOS



```

sarscov2_codon_network_generator.ipynb
Arquivo Editar Ver Inserir Ambiente de execução Ferramentas Ajuda

Comandos + Código + Texto ▶ Executar tudo

Arquivos
Conectando a um ambiente de execução para ativar a navegação de arquivos.

# Ligação direcionada seq -> pseq
lig = get_lig(gseq, pseq)
if lig:
    lig['count'] += 1
else:
    gseq['lig'].append({'seq': pseq, 'count': 1})

# ---- Construção das transições ----
for i in range(0, len(row) - 5, 3):
    seq = row[i:i + 3]
    pseq = row[i + 3:i + 6]

    add_to_graph(graph, seq)
    add_to_graph(graph, pseq)
    make_ligacao(graph, seq, pseq)

# ---- Contagem total dos códons ----
for i in range(0, len(row) - 2, 3):
    seq = row[i:i + 3]
    node = get_node(graph, seq)
    node['count'] += 1

# ---- Impressão ----

```

Figura 2: Trecho de código – Construção da rede de códons (WS=3; ST=3). Fonte. Os autores (2025).

O algoritmo da Figura 2, implementa a construção da rede de códons utilizando uma abordagem sequencial baseada em janelas não sobrepostas (*window size* = 3; *step size* = 3). A cada iteração, dois códons consecutivos são extraídos e conectados por uma aresta direcionada, cujo peso representa o número de transições observadas na sequência genômica completa. O dicionário *graph* armazena, para cada códon, sua frequência total e o conjunto de códons para os quais ele transita.

Essa estrutura gera um grafo direcionado e ponderado, preservando a ordem real da cadeia nucleotídica — uma diferença fundamental em relação ao método BASiNET original, que utiliza grafos não direcionados. Essa decisão metodológica permite capturar padrões de conectividade funcional que refletem diretamente a dinâmica estrutural da sequência do SARS-CoV-2.




Figura 3: Grafo Direcionado de Transições entre Códons. Fonte. Os autores (2025).

A Figura 3 ilustra um exemplo simplificado da rede de códons construída a partir do modelo utilizado neste estudo. Cada nó representa um códon distinto e cada aresta direcionada indica uma transição observada entre dois códons consecutivos na sequência biológica. Os números associados às arestas correspondem ao peso da ligação, isto é, à frequência com que cada transição ocorre no genoma analisado.

No exemplo, o códon ACT apresenta múltiplas conexões saindo dele, refletindo sua capacidade de transitar para diferentes códons subsequentes, como TAT, GAA e TCC, com pesos distintos. O códon GAA ocupa uma posição central, recebendo transições de ACT e

PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC OURINHOS

TAT, e distribuindo arestas para TCC e AAC. Por sua vez, AAC forma parte de um ciclo funcional ao retornar a ACT, sugerindo padrões estruturais recorrentes dentro da rede.

Essa representação evidencia como a abordagem baseada em redes captura não apenas a presença dos códons, mas também as relações dinâmicas entre eles. Ao destacar a direção e a intensidade das transições, o grafo permite visualizar, de forma intuitiva, propriedades funcionais da sequência, como ciclos, nós altamente conectados e caminhos preferenciais. Esse tipo de descrição gráfica complementa as análises quantitativas e reforça a capacidade do modelo de revelar padrões estruturais não triviais do genoma viral.

Assim, foi gerado um grafo direcionado e ponderado, distinto do grafo não direcionado empregado no BASiNET. Essa escolha metodológica preserva a ordem sequencial do genoma viral e possibilita avaliar padrões de conectividade funcional.

3 RESULTADOS E DISCUSSÃO PRELIMINARES

A sequência analisada contém 29.883 nucleotídeos, correspondendo a 9.961 códons. A distribuição de frequência evidenciou predominância de alguns códons específicos, conforme ilustrado na Tabela 1.

Tabela 1 – Métricas Topológicas de Grau dos 10 Códons mais frequentes do SARS-CoV-2

Nº	Códon	Aminoácido	Frequência	Grau de Saída	Grau de Entrada	Grau Total
1	TTT	Fenilalanina (F)	378	29	30	59
2	TGT	Cisteína (C)	374	24	30	54
3	TAA	STOP (códon de parada)	355	29	29	58
4	TCT	Serina (S)	349	31	30	61
5	TGG	Triptofano (W)	348	29	30	59
6	GGT	Glicina (G)	331	28	30	58
7	GAA	Ácido Glutâmico (E)	330	28	27	55
8	AGA	Arginina (R)	326	30	28	58
9	CTT	Leucina (L)	323	31	30	61
10	ATT	Isoleucina (I)	318	29	31	60

Fonte. Os autores (2025).

Tabela 1 consolida a frequência absoluta e as métricas de centralidade de grau para os 10 códons mais abundantes no genoma do SARS-CoV-2. A análise de frequência confirma a predominância de códons ricos em timidina (T), com TTT (Fenilalanina) sendo o mais frequente (378 ocorrências), seguido de TGT (Cisteína) e TAA (códon de parada). A presença

PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC OURINHOS

de um códon de terminação entre os mais abundantes pode refletir padrões estruturais específicos do genoma viral, especialmente em regiões não codificantes ou limites de ORFs.

No entanto, a caracterização da rede de transições, que é a aplicação central deste trabalho, revela padrões de conectividade que vão além da simples abundância. O Grau de Entrada (*In-degree*) identifica os principais hubs de convergência. O códon ATT (Isoleucina) apresentou o maior Grau de Entrada ($In-degree = 31$), atuando como um ponto de recebimento crucial na rede, sendo precedido por uma maior diversidade de códons distintos do que qualquer outro.

Simultaneamente, os códons TCT e CTT exibem o maior Grau de Saída ($Out-degree = 31$), indicando a maior diversidade de transições subsequentes e, consequentemente, injetando maior variabilidade no fluxo da sequência. A alta interconectividade geral desses códons (Grau Total = 61) comprova a formação de subestruturas densas e a existência de hubs, validando as observações visuais da rede (Figura 5).




Figura 4: Top 20 Códons por Frequência no Genoma do SARS-CoV-2. Fonte. Os autores (2025).

A construção da rede de transição (Figura 5) revelou alta conectividade entre determinados códons, formando subestruturas densas dentro do grafo. Isso sugere padrões recorrentes de organização genética que podem estar associados a regiões conservadas do RNA viral.

PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC OURINHOS




Figura 5: Rede de Transições entre os 30 Códon Mais Frequentes do SARS-CoV-2. Fonte. Os autores (2025).

A análise dessas transições é útil em estudos comparativos, especialmente para detecção de mutações que alterem a estrutura das conexões entre códon consecutivos.

A principal diferença reside na unidade de análise: enquanto o BASiNET utiliza janelas deslizantes de nucleotídeos, este trabalho utiliza códon completos. Essa adaptação não viola os princípios fundamentais da metodologia e pode até enriquecer análises relacionadas a tradução proteica e evolução viral.

Por fim, vale destacar que este trabalho concentra-se na etapa de mapeamento em rede, equivalente ao primeiro estágio do BASiNET, incluindo o cálculo de métricas topológicas básicas, especialmente as métricas de grau (in-degree e out-degree), não abrangendo ainda métricas mais avançadas como modularidade, assortatividade ou centralidade espectral. A ênfase reside na construção, visualização e análise inicial da rede de códon, que pode futuramente ser integrada a classificadores baseados em aprendizado de máquina, como proposto no BASiNET.

4 CONSIDERAÇÕES PRELIMINARES

Em suma, este trabalho alcançou o objetivo preliminar de adaptar o *framework* BASiNET ao nível de códon, resultando na construção e análise de uma rede de transições direcionadas para o genoma completo do SARS-CoV-2. Os resultados de frequência confirmam a predominância de códon ricos em timidina (T), sendo TTT o mais abundante, consistente com o viés de composição do genoma viral. Mais criticamente, a análise das métricas de grau demonstrou a existência de hubs de conectividade topológica na rede. O códon ATT apresentou o maior Grau de Entrada (*In-degree* = 31), estabelecendo-se como o principal *hub* de convergência. Por sua vez, os códon TCT e CTT exibiram o maior Grau de Saída (*Out-degree* = 31), indicando serem os principais injetores de diversidade sequencial

PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC OURINHOS

subsequente. Essas descobertas validam a representação da rede de códons como uma ferramenta eficaz para capturar características estruturais do genoma.

O desenvolvimento deste estudo contou com o apoio do Centro Paula Souza (CPS) e do Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq), por meio do Programa Institucional de Bolsas de Iniciação Científica (PIBIC CPS-CNPq). Projeto nº 187093/2025-3, pelo apoio financeiro.

REFERÊNCIAS

ANDERSEN, K. G. et al. **The proximal origin of SARS-CoV-2.** *Nature Medicine*, New York, v. 26, p. 450–452, 2020.

BRYANT, J. E. et al. **Lessons from the evolutionary dynamics of the SARS-CoV-2 genome.** *Nature Reviews Genetics*, London, v. 22, n. 11, p. 725–736, 2021.

CHAN, J. F. et al. **Genomic characterization of the 2019 novel human-pathogenic coronavirus isolated from a patient with atypical pneumonia.** *Emerging Microbes & Infections*, London, v. 9, p. 221–236, 2020.

HAGBERG, A.; SCHULT, D.; SWART, P. **Exploring network structure using NetworkX.** In: *Proceedings of the 7th Python in Science Conference*, Pasadena, 2008. p. 11–15.

ITO, Eric Augusto et al. **BASiNET—BiologicAl Sequences NETwork: a case study on coding and non-coding RNAs identification.** *Nucleic Acids Research*, v. 46, n. 16, p. e96, 2018.

MOUNT, D. W. *Bioinformatics: sequence and genome analysis*. 2. ed. New York: Cold Spring Harbor Laboratory Press, 2004.

NCBI. **Severe acute respiratory syndrome coronavirus 2 isolate Wuhan-Hu-1, complete genome.** Disponível em: <https://www.ncbi.nlm.nih.gov>. Acesso em: 28 nov. 2025.

PYTHON SOFTWARE FOUNDATION. *Python Language Reference, version 3.12*. Disponível em: <https://www.python.org>. Acesso em: 28 nov. 2025.

WU, F. et al. **A new coronavirus associated with human respiratory disease in China.** *Nature*, London, v. 579, p. 265–269, 2020.

ZHOU, P. et al. **A pneumonia outbreak associated with a new coronavirus of probable bat origin.** *Nature*, London, v. 579, p. 270–273, 2020.

PARECER DE ORIENTAÇÃO – Edição 2025/2026

1 – IDENTIFICAÇÃO DO RELATÓRIO

PROGRAMA INSTITUCIONAL DE BOLSAS DE INICIAÇÃO EM DESENVOLVIMENTO TECNOLÓGICO E INOVAÇÃO (PIBITI CPS-CNPq) - FATEC OURINHOS

Nome do Bolsista: Kelven Bertanha do Nascimento

Nome do Orientador: Prof. Dr. Isaque Katahira

Especificação: Relatório Parcial intitulado

“Aplicação de Redes Complexas e Aprendizado de Máquina para Classificação de Sequências Biológicas e Similares”

Modalidade: Iniciação Tecnológica (IT)

Período: 08/09/2025 a 27/02/2026

2 – APRECIÇÃO DO ORIENTADOR

O relatório apresenta desenvolvimento consistente das etapas previstas, com inovação metodológica relevante e resultados parciais satisfatórios.

3 – AVALIAÇÃO DO DESEMPENHO ACADÊMICO

O estudante demonstra domínio técnico, autonomia na programação e comprometimento científico.

4 – AVALIAÇÃO DAS ATIVIDADES

As atividades estão alinhadas ao cronograma aprovado e apresentam progresso adequado.

5 – COMENTÁRIOS GERAIS

Recomenda-se a continuidade do projeto.

Ourinhos, 16 de fevereiro de 2026.

Prof. Dr. Isaque Katahira

Orientador – Iniciação Tecnológica

Fatec Ourinhos